

# QR Box-Dual FedPDHG 的收敛阶数说明

FED-QR 项目

2026 年 6 月 10 日

## 摘要

本文给出 QR box-dual FedPDHG 方法的一个可用于报告或论文草稿的中文收敛性说明。核心结论是：在全客户端、全样本、确定性更新下，QR box-dual PDHG 可以得到  $\mathcal{O}(1/T)$  的遍历 primal-dual gap 收敛阶数；在随机联邦设定下，即存在客户端随机抽样、用户 mini-batch 抽样以及 cached direction 的 stale 误差时，不用方差缩减也可以证明  $\mathcal{O}(1/\sqrt{T})$  阶的随机收敛率。固定步长时，方法通常收敛到一个由随机方差和 stale bias 决定的误差邻域。方差缩减不是收敛证明的必要条件，它主要降低随机方差常数并改善稳定性。

## 1 问题形式与对偶盒结构

考虑带惩罚项的分位数回归问题

$$\min_{\beta \in \mathbb{R}^p} F(\beta) := \frac{1}{n} \sum_{i=1}^n \rho_{\tau}(y_i - x_i^{\top} \beta) + r(\beta), \quad (1)$$

其中

$$\rho_{\tau}(u) = u(\tau - \mathbf{1}\{u < 0\})$$

是分位数回归的 check loss,  $\tau \in (0, 1)$  是分位数水平,  $r(\beta)$  是惩罚项。在理论部分, 我们先假设  $r$  是 proper、closed、convex 的函数; 如果使用 MCP/SCAD 等非凸惩罚, 则严格全局收敛结论需要改成 stationary-point 类型结论。

check loss 的关键结构是 Fenchel 对偶盒表示:

$$\rho_{\tau}(u) = \max_{v \in [\tau-1, \tau]} vu. \quad (2)$$

因此, 原问题 (1) 可以写成 convex-concave saddle point 问题:

$$\min_{\beta \in \mathbb{R}^p} \max_{v \in \mathcal{V}} \mathcal{L}(\beta, v) := r(\beta) + \frac{1}{n} v^{\top} (y - X\beta), \quad \mathcal{V} := [\tau-1, \tau]^n. \quad (3)$$

QR box-dual 方法的核心正是利用这个盒约束对偶变量:

$$v_i \in [\tau-1, \tau].$$

算法每轮对  $v_i$  做盒投影更新, 并对  $\beta$  做 primal proximal update。

## 2 确定性全量版本: $\mathcal{O}(1/T)$

首先考虑最理想的确定性版本:

- 所有客户端每轮都参与;
- 每个客户端每轮都刷新全部本地样本的 dual variables;
- 不存在客户端抽样随机性;
- 不存在用户 mini-batch 随机性;
- 不存在 stale cached direction。

**假设 1** (确定性 PDHG 条件). 惩罚项  $r$  是 *proper*、*closed*、*convex* 的函数。矩阵  $X$  的谱范数有限。步长  $\eta, \sigma > 0$  满足

$$\eta\sigma \frac{\|X\|_2^2}{n^2} < 1. \quad (4)$$

**定理 1** (确定性 QR box-dual PDHG 的遍历收敛阶数). 在假设 1 下, 令  $(\beta^t, v^t)$  为全量确定性 QR box-dual PDHG 生成的迭代序列。定义遍历平均

$$\bar{\beta}^T = \frac{1}{T} \sum_{t=1}^T \beta^t, \quad \bar{v}^T = \frac{1}{T} \sum_{t=1}^T v^t.$$

若  $(\beta^*, v^*)$  是 *saddle point*, 则有

$$\mathcal{G}(\bar{\beta}^T, \bar{v}^T) := \mathcal{L}(\bar{\beta}^T, v^*) - \mathcal{L}(\beta^*, \bar{v}^T) \leq \frac{1}{T} \left( \frac{\|\beta^* - \beta^0\|^2}{2\eta} + \frac{\|v^* - v^0\|^2}{2\sigma} \right). \quad (5)$$

因此, 全量确定性 QR box-dual PDHG 的遍历 *primal-dual gap* 收敛阶数为

$$\mathcal{O}(1/T).$$

**证明思路.** 将 (3) 写成标准 PDHG 形式:

$$r(\beta) + \langle K\beta, v \rangle - h^*(v), \quad K = -X/n,$$

其中

$$h^*(v) = -v^\top y/n + \iota_{\mathcal{V}}(v),$$

$\iota_{\mathcal{V}}$  是集合  $\mathcal{V}$  的 indicator function。dual update 正是  $h^*$  的 proximal step, 也就是带 affine shift 后投影到  $[\tau - 1, \tau]^n$ ; primal update 是  $r$  的 proximal step。

由标准 PDHG 一步下降不等式可得, 对任意  $(\beta, v)$ ,

$$\begin{aligned} \mathcal{L}(\beta^{t+1}, v) - \mathcal{L}(\beta, v^{t+1}) &\leq \frac{1}{2\eta} (\|\beta - \beta^t\|^2 - \|\beta - \beta^{t+1}\|^2) \\ &\quad + \frac{1}{2\sigma} (\|v - v^t\|^2 - \|v - v^{t+1}\|^2). \end{aligned} \quad (6)$$

对  $t = 0, \dots, T-1$  求和后, 右侧平方距离项 telescoping。再令  $(\beta, v) = (\beta^*, v^*)$ , 并利用  $\mathcal{L}$  对  $\beta$  的凸性和对  $v$  的凹性, 即可得到 (5)。□

### 3 随机联邦版本：不用方差缩减时的 $\mathcal{O}(1/\sqrt{T})$

真实的联邦 QR box-dual 方法不是确定性全量更新，而是包含：

- 每轮只抽取一部分客户端；
- 被抽中的客户端只用 mini-batch 用户更新 dual variables；
- 未被抽中的客户端使用 cached direction；
- cached direction 会产生 stale bias；
- stochastic direction 存在随机方差。

令  $\hat{g}^t$  表示服务器第  $t$  轮实际使用的随机 cached primal direction， $g^t$  表示理想全量方向。

**假设 2** (随机联邦条件). 存在有限常数  $R, V, \Sigma, D$ ，使得：

1. 协变量有界： $\|x_i\| \leq R$ ；
2. dual variable 天然有界：

$$v_i^t \in [\tau - 1, \tau], \quad |v_i^t| \leq V := \max\{\tau, 1 - \tau\};$$

3. stochastic direction 方差有界：

$$\mathbb{E} [\|\hat{g}^t - \mathbb{E}(\hat{g}^t | \mathcal{F}_t)\|^2 | \mathcal{F}_t] \leq \Sigma^2; \quad (7)$$

4. stale cache bias 满足

$$\|\mathbb{E}(\hat{g}^t | \mathcal{F}_t) - g^t\| \leq \Delta_t, \quad \frac{1}{T} \sum_{t=0}^{T-1} \Delta_t \leq \bar{\Delta}_T; \quad (8)$$

5. 迭代点停留在有界 level set 中，其直径不超过  $D$ 。

**定理 2** (随机联邦 QR box-dual 的收敛阶数). 在假设 2 下，令随机联邦 QR box-dual 使用

$$\eta_t = \sigma_t = \gamma/\sqrt{T}$$

形式的步长，其中  $\gamma$  足够小以满足 PDHG 稳定条件。则其遍历 primal-dual gap 满足

$$\mathbb{E} [\mathcal{G}(\bar{\beta}^T, \bar{v}^T)] \leq \frac{C_1}{\sqrt{T}} + C_2 \bar{\Delta}_T, \quad (9)$$

其中  $C_1$  与初始距离、 $\gamma$ 、随机方差上界  $\Sigma^2$  有关， $C_2$  与有界 level set 的直径有关。若平均 stale bias 满足

$$\bar{\Delta}_T = \mathcal{O}(T^{-1/2}),$$

则

$$\mathbb{E} [\mathcal{G}(\bar{\beta}^T, \bar{v}^T)] = \mathcal{O}(T^{-1/2}).$$

证明思路. 随机情形的证明是在确定性 PDHG 一步不等式的基础上加入随机误差项。因为实际使用的是  $\hat{g}^t$  而不是  $g^t$ ，所以多出

$$\langle \hat{g}^t - g^t, \beta^{t+1} - \beta \rangle.$$

将误差分解为两部分：

$$\hat{g}^t - g^t = \underbrace{\hat{g}^t - \mathbb{E}(\hat{g}^t | \mathcal{F}_t)}_{\text{martingale noise}} + \underbrace{\mathbb{E}(\hat{g}^t | \mathcal{F}_t) - g^t}_{\text{stale cache bias}}.$$

第一项是零均值随机噪声，由方差上界 (7) 控制；第二项由 (8) 控制。

对一步不等式求和后，确定性部分仍然 telescoping；随机噪声部分通过 Young 不等式产生

$$\sum_{t=0}^{T-1} \eta_t \Sigma^2$$

量级的项；stale bias 产生

$$D \sum_{t=0}^{T-1} \Delta_t$$

量级的项。两边除以  $\sum_{t=0}^{T-1} \eta_t$  后得到

$$\frac{C}{\sum_{t=0}^{T-1} \eta_t} + \frac{\sum_{t=0}^{T-1} \eta_t^2 \Sigma^2}{\sum_{t=0}^{T-1} \eta_t} + C_2 \bar{\Delta}_T.$$

取  $\eta_t = \Theta(T^{-1/2})$ ，即可得到 (9)。 □

## 4 固定步长时的误差邻域

实际实验中我们常使用固定步长。固定步长下，随机误差不会完全消失，因此更合理的结论是收敛到一个误差邻域：

$$\mathbb{E} [\mathcal{G}(\bar{\beta}^T, \bar{v}^T)] \leq \frac{C_3}{\eta T} + C_4 \eta \Sigma^2 + C_5 \bar{\Delta}_T. \quad (10)$$

其中第一项是  $\mathcal{O}(1/T)$  的 transient term，后两项分别来自随机方差和 stale cache bias。因此固定步长不是严格收敛到零 gap，而是收敛到 variance/staleness-dependent neighborhood。

## 5 stale、robust、adaptive 对理论的影响

staleness-aware 和 robust/adaptive 方法在服务器聚合时使用客户端权重  $w_j^t$ 。如果这些权重满足

$$0 < w_{\min} \leq w_j^t \leq w_{\max} < 1, \quad \sum_{j=1}^m w_j^t = 1,$$

则上述随机收敛阶数不发生本质变化，只是常数和优化目标发生变化。

**sample weighting.** 如果

$$w_j = n_j/n,$$

则优化的是原始 sample-average empirical risk。

**uniform/custom weighting.** 如果使用 uniform 或 custom client weighting, 则理论对应的目标变为 client-weighted 分位数回归:

$$F_w(\beta) = \sum_{j=1}^m w_j \frac{1}{n_j} \sum_{i \in \mathcal{D}_j} \rho_\tau(y_i - x_i^\top \beta) + r(\beta). \quad (11)$$

这解释了为什么 robust 方法可能牺牲 global sample-average objective, 却改善 worst-client loss。

**adaptive weighting.** adaptive weighting 可以看成优化一个缓慢变化的 client-weighted saddle problem。如果权重有界且总变化量有限, 例如

$$\sum_{t=0}^{T-1} \|w^{t+1} - w^t\|_1 < \infty,$$

则额外项可以作为 lower-order variation error 加入收敛界中。

## 6 方差缩减的作用

方差缩减不是证明收敛阶数的必要条件。不使用方差缩减时, 随机联邦版本已经可以在上述假设下得到  $\mathcal{O}(1/\sqrt{T})$  阶。

control-variate VR 的作用是降低随机方差常数。若校正后的方向  $\hat{g}_{\text{vr}}^t$  满足

$$\mathbb{E} [\|\hat{g}_{\text{vr}}^t - \mathbb{E}(\hat{g}_{\text{vr}}^t | \mathcal{F}_t)\|^2 | \mathcal{F}_t] \leq \Sigma_{\text{vr}}^2 \leq \Sigma^2,$$

则定理 2 中的  $\Sigma^2$  可以替换为更小的  $\Sigma_{\text{vr}}^2$ 。因此 VR 改善的是常数, 而不是在一般 nonsmooth 随机联邦设定下直接把阶数从  $\mathcal{O}(1/\sqrt{T})$  变成  $\mathcal{O}(1/T)$ 。

## 7 总结

综上, 理论结论可以概括为:

- 全量确定性 QR box-dual PDHG: 遍历 primal-dual gap 为  $\mathcal{O}(1/T)$ ;
- 随机联邦 QR box-dual, 不用方差缩减: 在 bounded variance 和 bounded stale bias 条件下为  $\mathcal{O}(1/\sqrt{T})$ ;
- 固定步长随机版本: 收敛到由随机方差和 stale bias 决定的误差邻域;
- robust/adaptive weighting 不改变基本阶数, 但改变目标和常数;
- 方差缩减降低 variance constant, 主要改善稳定性和公平性, 不是主收敛证明的必要条件。