

分位数回归盒对偶联邦原始-对偶混合梯度法的严格收敛阶数证明

项目组

2026 年 6 月 10 日

摘要

本文给出分位数回归盒对偶联邦原始-对偶混合梯度法在一个明确随机联邦模型下的收敛阶数证明。证明中显式定义客户端抽样、用户小批量抽样、缓存方向以及陈旧偏差，并给出依赖客户端参与数、小批量大小、客户端不均衡因子和最大缓存延迟的收敛界。主要结论如下：在全客户端、全样本的确定性情形下，遍历原始-对偶间隙具有 $\mathcal{O}(1/T)$ 收敛阶数；在随机联邦、部分客户端参与和小批量更新下，即使不使用方差缩减，也可以得到 $\mathcal{O}(1/\sqrt{T})$ 的期望遍历间隙界。方差缩减可以降低方差常数，但不是得到该阶数的必要条件。

1 问题、联邦划分与鞍点形式

定义 1 (带惩罚的分位数回归问题). 给定数据 $\{(x_i, y_i)\}_{i=1}^n$, 其中 $x_i \in \mathbb{R}^p$, 考虑

$$\min_{\beta \in \mathcal{B}} F(\beta) := \frac{1}{n} \sum_{i=1}^n \rho_{\tau}(y_i - x_i^{\top} \beta) + r(\beta), \quad (1)$$

其中 $\mathcal{B} \subset \mathbb{R}^p$ 是闭凸有界集合, r 是真闭凸惩罚函数,

$$\rho_{\tau}(u) = u(\tau - \mathbf{1}\{u < 0\}), \quad \tau \in (0, 1),$$

为分位数回归的检查损失。

说明 1. 这里显式加入有界集合 $\mathcal{B}$, 是为了使随机误差项中的内积具有有限上界。在实际算法中, 这可以由投影、参数截断、强制惩罚项, 或者有界水平集条件保证。若使用最小最大凹惩罚或平滑截断绝对偏差惩罚等非凸惩罚, 则严格全局鞍点收敛结论需改写为驻点型结论; 本文证明针对凸惩罚情形。

数据被划分到 m 个客户端:

$$\mathcal{D}_1, \dots, \mathcal{D}_m, \quad n_j = |\mathcal{D}_j|, \quad q_j = \frac{n_j}{n}, \quad \sum_{j=1}^m q_j = 1.$$

客户端 j 的设计矩阵和对偶变量分别记为 X_j 与 v_j 。

定义 2 (盒对偶表示). 检查损失满足芬歇尔盒对偶表示

$$\rho_\tau(u) = \max_{v \in [\tau-1, \tau]} vu. \quad (2)$$

因此, 问题 (1) 等价于凸凹鞍点问题

$$\min_{\beta \in \mathcal{B}} \max_{v \in \mathcal{V}} \mathcal{L}(\beta, v) := r(\beta) + \frac{1}{n} v^\top (y - X\beta), \quad \mathcal{V} = [\tau - 1, \tau]^n. \quad (3)$$

定义 3 (客户端局部方向与全量方向). 定义客户端 j 的局部方向为

$$d_j(v_j) := \frac{1}{n_j} X_j^\top v_j. \quad (4)$$

全量原始变量更新方向为

$$g(v) := \frac{1}{n} X^\top v = \sum_{j=1}^m q_j d_j(v_j). \quad (5)$$

分位数回归盒对偶联邦原始-对偶混合梯度法在服务器端使用 $g(v)$ 或其随机联邦估计量更新 β 。

2 基本假设与有界性引理

假设 1 (有界性与凸性). 存在常数 $R, D_\beta, Y_B < \infty$, 使得:

1. 对所有样本, $\|x_i\| \leq R$;
2. 集合 $\mathcal{B}$ 的直径不超过 D_β , 即任意 $\beta, \beta' \in \mathcal{B}$ 满足

$$\|\beta - \beta'\| \leq D_\beta;$$

3. 对所有 $\beta \in \mathcal{B}$, 残差有界:

$$|y_i - x_i^\top \beta| \leq Y_B;$$

4. r 是真闭凸函数, 并且其近端映射在 $\mathcal{B}$ 上良定义。

假设 2 (鞍点存在). 鞍点问题 (3) 至少存在一个鞍点, 记为 (β^*, v^*) 。也就是说, 对任意 $(\beta, v) \in \mathcal{B} \times \mathcal{V}$,

$$\mathcal{L}(\beta^*, v) \leq \mathcal{L}(\beta^*, v^*) \leq \mathcal{L}(\beta, v^*).$$

在本文假设下, 若 $\mathcal{B}$ 非空紧凸、 $\mathcal{V}$ 非空紧凸, 且 r 在 $\mathcal{B}$ 上下半连续, 则该条件由极小极大定理保证。

引理 1 (局部方向有界). 令

$$V_\tau := \max\{\tau, 1 - \tau\}.$$

由于 $v_i \in [\tau - 1, \tau]$, 对任意客户端 j 和任意 v_j , 有

$$\|d_j(v_j)\| \leq R V_\tau =: G. \quad (6)$$

证明. 由三角不等式和假设 1,

$$\|d_j(v_j)\| = \left\| \frac{1}{n_j} \sum_{i \in \mathcal{D}_j} x_i v_i \right\| \leq \frac{1}{n_j} \sum_{i \in \mathcal{D}_j} \|x_i\| |v_i| \leq R V_\tau.$$

□

3 确定性全量方法的 $\mathcal{O}(1/T)$ 阶

先考虑没有任何随机性的基准情形：每一轮所有客户端都参与，并且每个客户端都刷新全部本地对偶变量。令

$$K_0 = -X/n.$$

假设 3 (确定性步长条件). 步长 $\eta, \sigma > 0$ 满足

$$\eta\sigma \|K_0\|_2^2 = \eta\sigma \frac{\|X\|_2^2}{n^2} < 1. \quad (7)$$

定理 1 (确定性全量方法的遍历收敛阶数). 在假设 1、2 和 3 下，令 (β^t, v^t) 为全量确定性盒对偶原始-对偶混合梯度迭代。定义

$$\bar{\beta}^T = \frac{1}{T} \sum_{t=1}^T \beta^t, \quad \bar{v}^T = \frac{1}{T} \sum_{t=1}^T v^t.$$

若 (β^*, v^*) 是 (3) 的鞍点，则

$$\mathcal{G}(\bar{\beta}^T, \bar{v}^T) := \mathcal{L}(\bar{\beta}^T, v^*) - \mathcal{L}(\beta^*, \bar{v}^T) \leq \frac{1}{T} \left(\frac{\|\beta^* - \beta^0\|^2}{2\eta} + \frac{\|v^* - v^0\|^2}{2\sigma} \right). \quad (8)$$

因此确定性全量方法的遍历原始-对偶间隙为 $\mathcal{O}(1/T)$ 。

证明. 问题 (3) 是标准凸凹鞍点问题：

$$r(\beta) + \langle K_0 \beta, v \rangle - h^*(v), \quad h^*(v) := -v^\top y/n + \iota_{\mathcal{V}}(v),$$

其中 $\iota_{\mathcal{V}}$ 是盒集合 $\mathcal{V}$ 的示性函数。对偶变量更新是 h^* 的近端步骤，即投影到 $\mathcal{V}$ ；原始变量更新是 r 的近端步骤。由原始-对偶混合梯度法的一步不等式，在 (7) 下，对任意 $(\beta, v) \in \mathcal{B} \times \mathcal{V}$ 有

$$\begin{aligned} \mathcal{L}(\beta^{t+1}, v) - \mathcal{L}(\beta, v^{t+1}) &\leq \frac{1}{2\eta} \left(\|\beta - \beta^t\|^2 - \|\beta - \beta^{t+1}\|^2 \right) \\ &\quad + \frac{1}{2\sigma} \left(\|v - v^t\|^2 - \|v - v^{t+1}\|^2 \right). \end{aligned} \quad (9)$$

令 $(\beta, v) = (\beta^*, v^*)$ ，并对 $t = 0, \dots, T-1$ 求和，右端平方距离项望远镜相消。再利用 $\mathcal{L}$ 对 β 的凸性和对 v 的凹性，将平均间隙转化为遍历平均点处的间隙，即得到 (8)。□

4 客户端抽样与小批量方差

下面给出随机联邦方向估计的显式方差界。

4.1 无缓存偏差时的随机方向估计

每轮从分布 $\{\pi_j\}_{j=1}^m$ 中有放回抽取 K 个客户端，记为 $J_{t,1}, \dots, J_{t,K}$ ，其中 $\pi_j > 0$ 且 $\sum_j \pi_j = 1$ 。在客户端 j 上，用大小为 B_j 的用户小批量构造局部方向估计 $\hat{d}_j^t$ ，满足

$$\mathbb{E}[\hat{d}_j^t \mid \mathcal{F}_t] = d_j(v_j^t), \quad \mathbb{E} \left[\left\| \hat{d}_j^t - d_j(v_j^t) \right\|^2 \mid \mathcal{F}_t \right] \leq \frac{G^2}{B_j}. \quad (10)$$

其中 $G = RV_\tau$ 来自引理 1。

定义 4 (逆概率加权方向估计). 定义全局方向估计量

$$\hat{g}^t = \frac{1}{K} \sum_{\ell=1}^K \frac{q_{J_{t,\ell}}}{\pi_{J_{t,\ell}}} \hat{d}_{J_{t,\ell}}^t. \quad (11)$$

该形式是标准逆概率加权估计, 用于修正客户端非均匀抽样带来的偏差。

引理 2 (客户端抽样与小批量方差界). 在上述抽样模型下,

$$\mathbb{E}[\hat{g}^t \mid \mathcal{F}_t] = g(v^t), \quad (12)$$

且存在一个绝对常数 $c_0 > 0$, 使得

$$\mathbb{E} \left[\|\hat{g}^t - g(v^t)\|^2 \mid \mathcal{F}_t \right] \leq \frac{c_0 G^2}{K} \sum_{j=1}^m \frac{q_j^2}{\pi_j} \left(1 + \frac{1}{B_j} \right) =: \Sigma_{K,B}^2. \quad (13)$$

证明. 无偏性由

$$\mathbb{E} \left[\frac{q_J}{\pi_J} \hat{d}_J^t \mid \mathcal{F}_t \right] = \sum_{j=1}^m \pi_j \frac{q_j}{\pi_j} d_j(v_j^t) = \sum_{j=1}^m q_j d_j(v_j^t) = g(v^t)$$

得到。由于 K 次抽样条件独立,

$$\mathbb{E} \left[\|\hat{g}^t - g(v^t)\|^2 \mid \mathcal{F}_t \right] \leq \frac{1}{K} \mathbb{E} \left[\left\| \frac{q_J}{\pi_J} \hat{d}_J^t \right\|^2 \mid \mathcal{F}_t \right].$$

又有

$$\mathbb{E} \left[\left\| \frac{q_J}{\pi_J} \hat{d}_J^t \right\|^2 \mid \mathcal{F}_t \right] \leq 2 \|d_J(v_J^t)\|^2 + 2 \mathbb{E} \left[\left\| \hat{d}_J^t - d_J(v_J^t) \right\|^2 \mid \mathcal{F}_t \right] \leq 2G^2 \left(1 + \frac{1}{B_J} \right).$$

代入上式即可得到 (13), 其中绝对常数可取 $c_0 = 2$. $\square$

说明 2 (客户端不均衡因子). 若 $\pi_j = 1/m$, 则

$$\sum_{j=1}^m \frac{q_j^2}{\pi_j} = m \sum_{j=1}^m q_j^2.$$

当客户端样本量均衡时, $q_j = 1/m$, 该项等于 1; 当客户端样本量高度不均衡时, 该项变大。因此, 客户端样本量不均衡会放大随机方向方差。

5 缓存方向的陈旧偏差

实际的缓存聚合并不总是使用当前 $d_j(v_j^t)$, 而是使用客户端上次被刷新时的方向。记客户端 j 在第 t 轮服务器可见的缓存时间为 $\tau_j(t) \leq t$, 缓存方向为

$$\tilde{d}_j^t := d_j(v_j^{\tau_j(t)}).$$

缓存全量聚合方向为

$$\tilde{g}^t = \sum_{j=1}^m q_j \tilde{d}_j^t.$$

假设 4 (有界缓存延迟). 存在整数 $A \geq 0$, 使得

$$0 \leq t - \tau_j(t) \leq A, \quad \text{对所有 } j, t \text{ 成立.}$$

此外, 对偶变量步长 σ_t 非增。

引理 3 (陈旧偏差显式界). 在假设 1 和 4 下,

$$\|\tilde{g}^t - g(v^t)\| \leq RY_B \sum_{s=t-A}^{t-1} \sigma_s \leq RY_B A \sigma_{t-A}, \quad (14)$$

其中当 $t - A < 0$ 时求和从 0 开始。

证明. 对偶变量的盒投影更新满足

$$v_i^{s+1} = \Pi_{[\tau-1, \tau]} \left(v_i^s + \sigma_s (y_i - x_i^\top \bar{\beta}^s) \right),$$

或其小批量分块版本。投影算子是非扩张的, 因此对任意被更新的坐标,

$$|v_i^{s+1} - v_i^s| \leq \sigma_s |y_i - x_i^\top \bar{\beta}^s| \leq \sigma_s Y_B.$$

未被更新的坐标变化为 0, 所以上式仍成立。于是对客户端 j ,

$$\begin{aligned} \|d_j(v_j^t) - d_j(v_j^{\tau_j(t)})\| &= \left\| \frac{1}{n_j} X_j^\top (v_j^t - v_j^{\tau_j(t)}) \right\| \\ &\leq \frac{1}{n_j} \sum_{i \in \mathcal{D}_j} \|x_i\| |v_i^t - v_i^{\tau_j(t)}| \\ &\leq R \sum_{s=\tau_j(t)}^{t-1} \sigma_s Y_B \leq RY_B \sum_{s=t-A}^{t-1} \sigma_s. \end{aligned}$$

对客户端按 q_j 加权求和, 并使用 $\sum_j q_j = 1$, 即可得到 (14)。 $\square$

6 随机缓存联邦方法的收敛阶数

令 $\hat{g}_{\text{缓}}^t$ 表示实际用于原始变量更新的随机缓存方向。写成

$$\hat{g}_{\text{缓}}^t = g(v^t) + \xi_t + b_t,$$

其中

$$\mathbb{E}[\xi_t \mid \mathcal{F}_t] = 0, \quad \mathbb{E}[\|\xi_t\|^2 \mid \mathcal{F}_t] \leq \Sigma_{K,B}^2, \quad \|b_t\| \leq \Delta_t.$$

由引理 3, 可取

$$\Delta_t = RY_B \sum_{s=t-A}^{t-1} \sigma_s.$$

引理 4 (随机一步不等式). 在假设 1 下, 若原始变量更新使用 $\hat{g}_{\text{缓}}^t$, 则对任意 $(\beta, v) \in \mathcal{B} \times \mathcal{V}$, 存在绝对常数 $c_1 > 0$, 使得

$$\begin{aligned} \mathbb{E}_t[\mathcal{L}(\beta^{t+1}, v) - \mathcal{L}(\beta, v^{t+1})] &\leq \frac{1}{2\eta_t} \left(\|\beta - \beta^t\|^2 - \mathbb{E}_t \|\beta - \beta^{t+1}\|^2 \right) \\ &\quad + \frac{1}{2\sigma_t} \left(\|v - v^t\|^2 - \mathbb{E}_t \|v - v^{t+1}\|^2 \right) \\ &\quad + c_1 \eta_t \Sigma_{K,B}^2 + D_\beta \Delta_t, \end{aligned} \quad (15)$$

其中 $\mathbb{E}_t[\cdot] = \mathbb{E}[\cdot | \mathcal{F}_t]$.

证明. 与确定性一步不等式相比, 唯一差异是原始变量更新方向从 $g(v^t)$ 变成 $g(v^t) + \xi_t + b_t$, 于是多出误差项

$$\langle \xi_t + b_t, \beta - \beta^{t+1} \rangle.$$

对零均值噪声项, 使用杨氏不等式:

$$\langle \xi_t, \beta - \beta^{t+1} \rangle \leq \frac{\eta_t}{2} \|\xi_t\|^2 + \frac{1}{2\eta_t} \|\beta - \beta^{t+1}\|^2.$$

第二项可吸收到近端三点不等式中的平方距离项; 取条件期望并用 $\mathbb{E}_t \|\xi_t\|^2 \leq \Sigma_{K,B}^2$, 得到 $c_1 \eta_t \Sigma_{K,B}^2$. 对偏差项, 利用 $\beta, \beta^{t+1} \in \mathcal{B}$:

$$\langle b_t, \beta - \beta^{t+1} \rangle \leq \|b_t\| \|\beta - \beta^{t+1}\| \leq D_\beta \Delta_t.$$

代回确定性一步不等式即得 (15). □

定理 2 (不用方差缩减时的显式 $\mathcal{O}(1/\sqrt{T})$ 阶). 假设 1、2 和 4 成立. 令

$$\eta_t = \sigma_t = \frac{\gamma}{\sqrt{T}}, \quad t = 0, \dots, T-1,$$

其中 γ 足够小, 使得原始-对偶混合梯度法的稳定条件成立. 则随机缓存联邦盒对偶方法的遍历间隙满足

$$\begin{aligned} \mathbb{E}[\mathcal{G}(\bar{\beta}^T, \bar{v}^T)] &\leq \frac{1}{\sqrt{T}} \left[\frac{D_\beta^2 + D_v^2}{2\gamma} + c_1 \gamma \frac{c_0 G^2}{K} \sum_{j=1}^m \frac{q_j^2}{\pi_j} \left(1 + \frac{1}{B_j} \right) \right] \\ &\quad + \frac{D_\beta}{T} \sum_{t=0}^{T-1} RY_B \sum_{s=t-A}^{t-1} \sigma_s, \end{aligned} \quad (16)$$

其中 $D_v := \sup_{v, v' \in \mathcal{V}} \|v - v'\|$. 进一步, 由 $\sigma_s = \gamma/\sqrt{T}$ 可得

$$\mathbb{E}[\mathcal{G}(\bar{\beta}^T, \bar{v}^T)] \leq \frac{1}{\sqrt{T}} \left[\frac{D_\beta^2 + D_v^2}{2\gamma} + c_1 \gamma \frac{c_0 G^2}{K} \sum_{j=1}^m \frac{q_j^2}{\pi_j} \left(1 + \frac{1}{B_j} \right) + D_\beta RY_B A \gamma \right]. \quad (17)$$

因此, 在 K, B_j, A 固定且有界的情况下, 不使用方差缩减也有

$$\mathbb{E}[\mathcal{G}(\bar{\beta}^T, \bar{v}^T)] = \mathcal{O}(T^{-1/2}).$$

证明. 记 $\eta = \gamma/\sqrt{T}$. 在引理 4 中取 $(\beta, v) = (\beta^*, v^*)$, 并对 $t = 0, \dots, T-1$ 求和. 平方距离项望远镜相消, 得到

$$\sum_{t=0}^{T-1} \mathbb{E}[\mathcal{L}(\beta^{t+1}, v^*) - \mathcal{L}(\beta^*, v^{t+1})] \leq \frac{D_\beta^2 + D_v^2}{2\eta} + c_1 \sum_{t=0}^{T-1} \eta_t \Sigma_{K,B}^2 + D_\beta \sum_{t=0}^{T-1} \Delta_t.$$

利用 $\mathcal{L}$ 的凸凹性, 将左侧转化为遍历平均点处的间隙, 再除以 T . 代入引理 2 的 $\Sigma_{K,B}^2$ 和引理 3 的 Δ_t , 得到 (16). 最后代入 $\eta_t = \sigma_t = \gamma/\sqrt{T}$, 并使用

$$\sum_{s=t-A}^{t-1} \sigma_s \leq A\gamma/\sqrt{T},$$

即可得到 (17). □

7 固定步长情形

推论 1 (固定步长误差邻域). 若采用固定步长 $\eta_t = \sigma_t = \eta$, 同样的推导给出

$$\mathbb{E}[\mathcal{G}(\bar{\beta}^T, \bar{v}^T)] \leq \frac{D_\beta^2 + D_v^2}{2\eta T} + c_1 \eta \Sigma_{K,B}^2 + D_\beta R Y_B A \eta. \quad (18)$$

因此固定步长有 $\mathcal{O}(1/T)$ 的暂态下降项, 但最终会停在由随机方差和陈旧偏差决定的邻域中:

$$\mathcal{O}(\eta \Sigma_{K,B}^2) + \mathcal{O}(A\eta).$$

8 陈旧加权、稳健加权、自适应加权与方差缩减

陈旧加权。 如果服务器使用陈旧程度权重 a_j^t , 并且

$$0 < a_{\min} \leq a_j^t \leq a_{\max} < \infty, \quad \sum_{j=1}^m q_j a_j^t = 1,$$

则上述证明保持成立, 只是 G 和陈旧偏差常数会乘上与 $a_{\max}/a_{\min}$ 有关的因子。

稳健加权。 如果使用等客户端权重或自定义客户端权重, 则目标从样本平均目标变为

$$F_w(\beta) = \sum_{j=1}^m w_j \frac{1}{n_j} \sum_{i \in \mathcal{D}_j} \rho_\tau(y_i - x_i^\top \beta) + r(\beta).$$

同样的证明适用于 F_w 对应的鞍点问题。这解释了为什么稳健版本可能牺牲样本平均目标值, 却改善最差客户端损失。

自适应加权。 若自适应权重 w_j^t 满足有界性和有限总变化量

$$0 < w_{\min} \leq w_j^t \leq w_{\max} < 1, \quad \sum_{t=0}^{T-1} \|w^{t+1} - w^t\|_1 < \infty,$$

则可视为求解一个缓慢变化的加权鞍点问题序列。收敛界中会多出权重变化项

$$\frac{1}{T} \sum_{t=0}^{T-1} \|w^{t+1} - w^t\|_1.$$

若该项为 $\mathcal{O}(T^{-1/2})$ 或更小, 则不改变主阶数。

方差缩减。 方差缩减不是得到定理 2 的必要条件。若方差缩减后的方向满足

$$\mathbb{E}[\|\hat{g}_{\text{vr}}^t - g(v^t)\|^2 \mid \mathcal{F}_t] \leq \Sigma_{\text{vr}}^2 \leq \Sigma_{K,B}^2,$$

则定理 2 仍成立，只需将 $\Sigma_{K,B}^2$ 替换为更小的 Σ_{vr}^2 。因此，方差缩减改善的是收敛界中的方差常数，而不是在一般非光滑随机联邦设定下把阶数从 $\mathcal{O}(T^{-1/2})$ 直接提升为 $\mathcal{O}(T^{-1})$ 。

9 结论

在明确的有界性、客户端抽样、小批量抽样和有界延迟假设下，我们得到：

- 全量确定性盒对偶原始-对偶混合梯度法：

$$\mathcal{G}(\bar{\beta}^T, \bar{v}^T) = \mathcal{O}(1/T).$$

- 随机联邦缓存盒对偶方法，不使用方差缩减：

$$\mathbb{E}[\mathcal{G}(\bar{\beta}^T, \bar{v}^T)] = \mathcal{O}(1/\sqrt{T}).$$

- 显式常数依赖客户端参与数 K 、小批量大小 B_j 、客户端不均衡因子 $\sum_j q_j^2/\pi_j$ 、最大缓存延迟 A 、协变量上界 R 和残差上界 $Y_{\mathcal{B}}$ 。
- 固定步长时，方法收敛到由随机方差和陈旧偏差决定的误差邻域。
- 方差缩减可以降低方差常数，但不是证明 $\mathcal{O}(1/\sqrt{T})$ 阶的必要条件。